## Bioinformatyka 2

ZBOiB WBBiB UJ Adrian Kania

28 października 2025

## **NCBI**

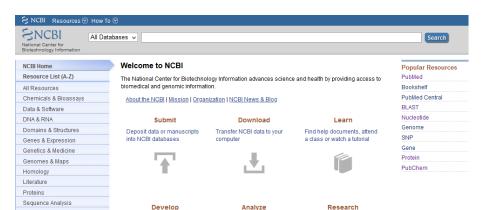
- NCBI National Center for Biotechnology Information
- NCBI Entrez zintegrowany system ponad 30 baz danych gromadzących informację z nauk biomedycznych, głównie w postaci sekwencji i literatury naukowej. Obejmuje m.in Pubmed (streszczenia publikacji), Nucleotide (sekwencje nukleotydowe), Protein (sekwencje aminokwasowe).
- Entrez Programming Utilities oprogramowanie umożliwiające dostęp do danych zintegrowanych w ramach systemu Entrez bez konieczności obsługi formularzy na stronach WWW
  - ESearch wyszukiwanie identyfikatorów/kodów dostępu rekordów wybranej bazy danych,
  - EFetch pobieranie rekordów o wskazanych identyfikatorach lub wyników wskazanego wyszukiwania

## **NCBI**

Taxonomy

Variation

Training & Tutorials





Use NCBI APIs and code

libraries to build applications

...

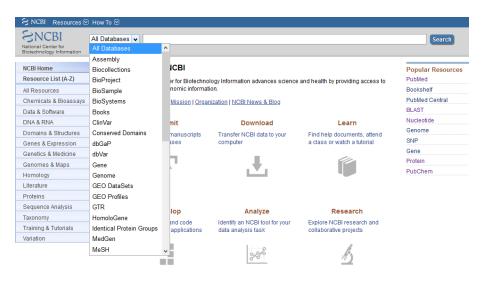
Identify an NCBI tool for your

data analysis task

Explore NCBI research and

collaborative projects

## **NCBI**



#### **EFetch**

## EFetch

EFetch (efetch.fcgi) returns full data records for a list of unique identifiers (UIDs) in a format specified in the parameters. The list of UIDs is either provided in the parameters, or is retrieved from the History server.

#### **EFetch Parameters**

#### **EFetch Required Parameters**

- discreptive (include): Database containing the unique identifiers (UIDs) for which you wish to retrieve records. You can see NCBI's table of Entrez Unique identifiers (UIDs) for a complete list of allowable database names, but some example values include:
  - o pubmed : PubMed
  - o pmc : PubMed Central
  - o nlmcatalog: NLM Catalog
- id (required): Either a single unique identifier (UID) or a comma-delimited list of UIDs. All of the UIDs must be from the database specified by the db parameter.

#### **EFetch Optional Parameters**

- retstart (optional): Setting this parameter helps limit which records will be shown in the output, as it determines whether the record for the first input unique identifier (UID) is retrieved, or whether to skip to a later UID in the input list. For example, if retstart is set to 10, the output will begin with the record for the tenth UID. The default of this parameter is 1, corresponding to the first UID in the input list. This parameter can be used in conjunction with retmax to download an arbitrary subset of records.
- returex (optional): Total number of records to be shown in the output, up to a maximum of 10,000. If the set of records you are trying to retrieve is larger than 10,000, you can submit multiple EFeIch requests, and increase the retstart parameter each time.
- restude/restype: These two parameters determine how your results will be displayed. restude determines the data format your records will be returned in (e.g. XML, plain text, etc.) restype determines the specific view your records will be returned in (e.g. MEDLINE, Abstract, list of PMIDs, etc.). Different databases have different allowable data formats and record views, and not all restude data formats are compatible with all restype record views, and vice versa.

The table below shows the allowable combinations of <a href="retmode">retmode</a> and <a href="retmode">retmode</a> and <a href="retmode">retmode</a> are the default data format for the specified database. **Bold** <a href="retmode">retmode</a> values are the default data format for the specified database. **Bold** <a href="retmode">retmode</a> values are the default data format for the specified data format and database.

#### EFetch Examples

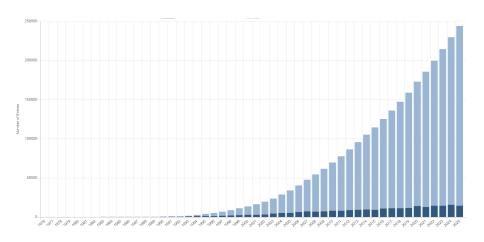
- Retrieve the abstract view (text format) of two PubMed records.
  - $\verb| https://eutils.ncbi.nlm.nih.gov/entrez/eutils/efetch.fcgi?db=pubmed\&id=17284678,9997\&retmode=text\&rettype=abstract | to be a construction of the construction of$
- · Retrieve two PubMed records in XML format.
  - $\verb| https://eutils.ncbi.nlm.nih.gov/entrez/eutils/efetch.fcgi?db=pubmed&id=11748933,11700088\&retmode=xmloretmode$

#### **ESearch**

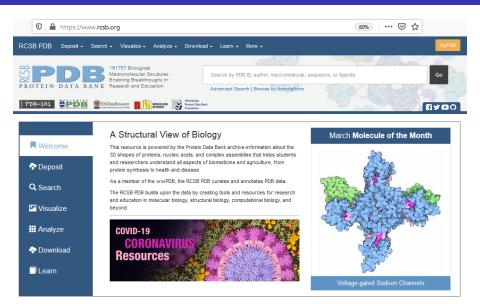
#### **ESearch Formatting Parameters**

- retstart (optional): Setting this parameter helps limit which of the unique identifiers (UIDs) in the results set will be shown in the output, as it determines whether the output begins at the first retrieved UID, or with a UID that is later in the results set. For example, if retstart is set to 10, the first ten UIDs in the results set will be skipped, and the output will begin with the eleventh UID. The default of this parameter is 0, corresponding to the first record in the entire set. This parameter and be used in conjunction with returns to download an arbitrary subset of UIDs retrieved from a search.
- retmax (optional): Total number of unique identifiers (UIDs) from the retrieved set to be shown in the output (default=20). Increasing retmax allows more of the retrieved UIDs to be included in the output, up to a maximum of 100,000 UIDs. If you need to retrieve more than 100,000 UIDs, you can submit multiple ESearch requests, and increase the retstart parameter each time. For example:
  - https://eutils.ncbi.nlm.nih.gov/entrez/eutils/esearch.fcgi?db=pubmed&term=cancer&retmax=100: This URL will return results 1 through 100 of a search for "Cancer"
  - https://eutils.ncbi.nlm.nih.gov/entrez/eutils/esearch.fcgi?db=pubmed&term=cancer&retstart=100&retmax=100: This URL will return results 101 through
     200 of the same search for "Cancer"
- · rettype (optional): Retrieval type. There are two supported values:
  - utlist (default): Displays the standard XML output, including a list of unique identifiers (UIDs), the total number of results, and the query translation for the search.
  - o count: Displays only the total number of results, without the list of UIDs or query translation.
- retmode (optional): Determines the format of the returned output. The default value is xm1, but json is also supported.

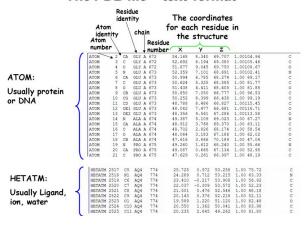
## PDB



### **PDB**



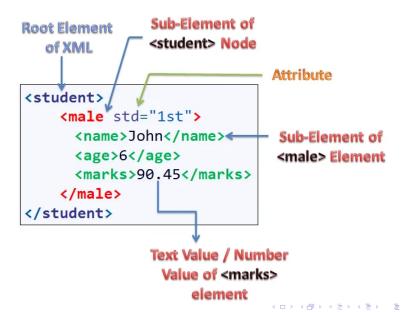
#### The PDB file - text format



# **XML**

- XML Extensible Markup Language rozszerzalny język znakowania przeznaczony do reprezentowania różnych danych w ustrukturalizowany sposób
  - znacznik ciąg liter, cyfr i innych znaków (bez spacji i zaczynający się od litery) ograniczony znakami < i >. Tagowi (znacznikowi) otwierającemu zawsze towarzyszy tag zamykający zaczynający się od znaków </ i kończący się znakiem >.
  - atrybut definiowany w obrębie znacznika, składa się zwykle pary nazwa = wartość, przy czym wartość zwykle podawana jest w cudzysłowach,
  - encja jest elementem treści dokumentu i reprezentuje pojedynczy symbol, encje definiuje się podając po znaku & numer symbolu i kończąc znakiem średnika, np & lt;

## **XML**



# XML

```
<eInfoResult>
  <DbInfo>
    <DbName>pubmed</DbName>
    <MenuName>PubMed</MenuName>
    <Description>PubMed bibliographic record</Description>
    <Count>22595116</Count>
    <LastUpdate>2013/03/19 03:50</LastUpdate>
    <FieldList>
       <Field>
         <Name>ALL</Name>
         <FullName>All Fields</FullName>
         <Description>All terms from all searchable fields</Description>
         <TermCount>139835112</TermCount>
         <IsDate>N</IsDate>
         <IsNumerical>N</IsNumerical>
         <SingleToken>N</SingleToken>
         <Hierarchy>N</Hierarchy>
         <IsHidden>N</IsHidden>
       </Field>
       <Field>
</eInfoResult>
```

# Wektory 2D - podstawowe operacje

Niech dane są v = (1, 2) oraz w = (4, 0). Wtedy:

**1** suma wekorów v i w wynosi:

$$v + w = (1 + 4, 2 + 0) = (5, 2),$$

**2** iloczyn skalarny wektorów v i w wynosi:

$$\langle v, w \rangle = 1 \cdot 4 + 2 \cdot 0 = 4 + 0 = 4$$

**1 długość wektora** *v* wynosi:

$$||v|| = \sqrt{\langle v, v \rangle} = \sqrt{1 \cdot 1 + 2 \cdot 2} = \sqrt{5}.$$

# Wektory 3D - podstawowe operacje

Niech dane są v = (1, 2, 3) oraz w = (4, 0, -2). Wtedy:

**1** suma wekorów v i w wynosi:

$$v + w = (1 + 4, 2 + 0, 3 + (-2)) = (5, 2, 1),$$

**②** iloczyn skalarny wektorów v i w wynosi:

$$< v, w > = 1 \cdot 4 + 2 \cdot 0 + 3 \cdot (-2) = 4 + 0 - 6 = -2,$$

długość wektora v wynosi:

$$||v|| = \sqrt{\langle v, v \rangle} = \sqrt{1 \cdot 1 + 2 \cdot 2 + 3 \cdot 3} = \sqrt{14}.$$

# Wektory ND - podstawowe operacje

Niech dane są  $v = (v_1, v_2, ..., v_n)$  oraz  $w = (w_1, w_2, ..., w_n)$ . Wtedy:

**1** suma wekorów v i w wynosi:

$$v + w = (v_1 + w_1, v_2 + w_2, ..., v_n + w_n),$$

**② iloczyn skalarny wektorów** *v* i *w* wynosi:

$$< v, w > = v_1 w_1 + v_2 w_2 + ... + v_n w_n$$

długość wektora v wynosi:

$$||v|| = \sqrt{\langle v, v \rangle} = \sqrt{v_1 v_1 + v_2 v_2 + \dots + v_n v_n} = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2}.$$

### Przestrzenie wektorowe a analiza tekstu

Zdanie1: new york times Zdanie2: new york post Zdanie3: los angeles times

### Przestrzenie wektorowe a analiza tekstu

**Dokument1**: new york times **Dokument2**: new york post **Dokument3**: los angeles times

Występujące słowa: angeles, los, new, post, times, york

### Przestrzenie wektorowe a analiza tekstu

```
Dokument1: new york times Dokument2: new york post Dokument3: los angeles times
```

```
Występujące słowa (w ilu tekstach): angeles (1), los (1), new (2), post (1), times (2), york (2)
```

# IDF (Inverse Document Frequency)

Liczba zdań N=3.

Występujące słowa (w ilu tekstach): angeles (1), los (1), new (2), post (1), times (2), york (2)

$$idf_i = \log_2(\frac{N}{df_i})$$

gdzie  $df_i$  - liczba dokumentów zawierających i-te słowo. Wtedy:

- angles,  $\log_2(\frac{3}{1}) = 1.584$ ,
- los,  $\log_2(\frac{3}{1}) = 1.584$ ,
- new,  $\log_2(\frac{3}{2}) = 0.584$ ,
- post,  $\log_2(\frac{3}{1}) = 1.584$ ,
- times,  $\log_2(\frac{3}{2}) = 0.584$ ,
- york,  $\log_2(\frac{3}{2}) = 0.584$ .

# TF (Term Frequency)

Niech:

 $f_{ij}$  - częstość i - tego słowa w dokumencie j.

Wtedy:

$$tf_{ij} = \frac{f_{ij}}{\max\{f_{ij}\}}$$
.

W naszym przypadku:

11	angeles	los	new	post	times	york
d1	0	Ü	1	0	1	1
d2	0	0	1	1	0	1
d3	1	1	0	0	1	0

## Ważenie TF-IDF

#### Definiujemy:

$$w_{ij} = tf_{ij}idf_i = tf_{ij}\log_2(\frac{N}{df_i}).$$

#### Uwaga:

- słowa występujące często w jakimś dokumencie, ale rzadko w pozostałych dokumentach będą miały wysoką wagę
- eksperymentalnie takie ważenie się sprawdza

## Ważenie TF-IDF

Definiujemy:

$$w_{ij} = tf_{ij}idf_i = tf_{ij}\log_2(\frac{N}{df_i}).$$

W naszym przypadku:

d1	angeles 0	0	0.584	0	0.584	0.584
d2	0	0	0.584	1.584	0	0.584
d3	1.584	1.584	0	0	0.584	0

## Zapytanie

Powiedzmy, że mamy nowy dokument:

new new times

Pytanie: Który dokument najbardziej przypomina?

## Zapytanie

Powiedzmy, że mamy nowy dokument:

new new times

Pytanie: Który dokument najbardziej przypomina? Należy obliczyć ważenie TD-IDF dla zapytania.

## Zapytanie

Powiedzmy, że mamy nowy dokument:

new new times

Pytanie: Który dokument najbardziej przypomina? Należy obliczyć ważenie  $TD-IDF\,$  dla zapytania.

# Wyznaczanie długości wektorów

#### Mamy:

• 
$$||d1|| = \sqrt{0.584^2 + 0.584^2 + 0.584^2} = 1.011$$
,

• 
$$||d2|| = \sqrt{0.584^2 + 1.584^2 + 0.584^2} = 1.786$$
,

• 
$$||d3|| = \sqrt{1.584^2 + 1.584^2 + 0.584^2} = 2.316$$
,

• 
$$||q|| = \sqrt{0.584^2 + 0.292^2} = 0.652.$$

# Podobieństwo pomiędzy wektorami

Mamy:

$$\cos(d,q) = \frac{\langle d,q \rangle}{||d||\cdot||q||}$$

Zadanie:

Wyznaczy miarę kosinus pomiędzy sekwencjami d1, d2, d3 a q.

# Podobieństwo pomiędzy wektorami

Mamy:

$$\cos(d,q) = \frac{\langle d,q \rangle}{||d||\cdot||q||}$$

• 
$$\cos(d1, q) = \frac{0.0 + 0.0 + 0.584 \cdot 0.584 + 0.0 + 0.584 \cdot 0.292 + 0.584 \cdot 0}{1.011 \cdot 0.652} = 0.776$$

• 
$$\cos(d2, q) = \frac{0.0 + 0.0 + 0.584 \cdot 0.584 + 1.584 \cdot 0 + 0.0.292 + 0.584 \cdot 0}{1.786 \cdot 0.652} = 0.292$$

• 
$$\cos(d3, q) = \frac{1.584 \cdot 0 + 1.584 \cdot 0 + 0.0.584 + 0.0 + 0.584 \cdot 0.292 + 0.0}{2.316 \cdot 0.652} = 0.112$$

W jakiej kolejności należałoby zwrócić dokumenty na podane zapytanie?